Processing spontaneous speech in deployed Spoken Language Understanding systems: a survey

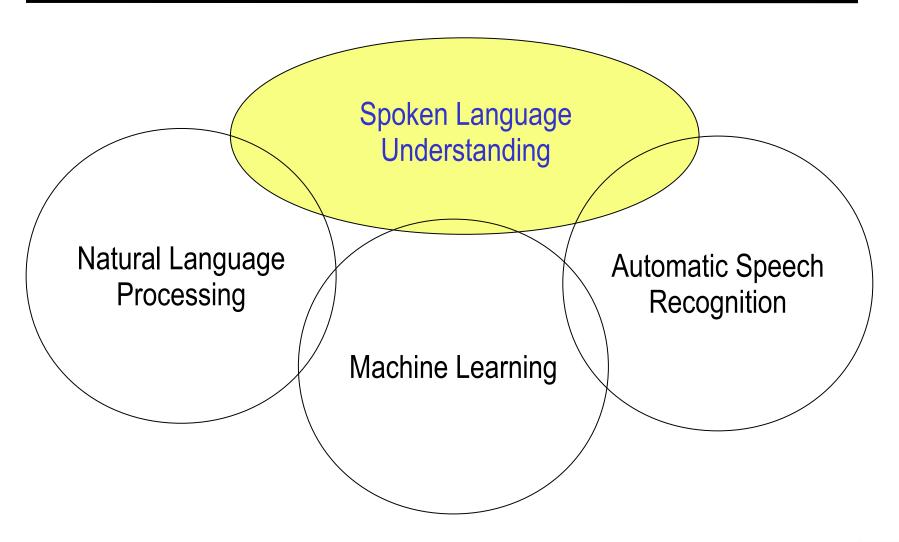
Frédéric Béchet

LIA, Université d'Avignon





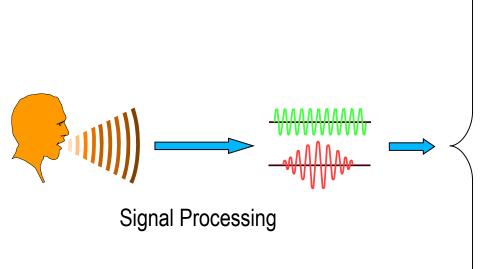
Framework







Spoken Language Understanding



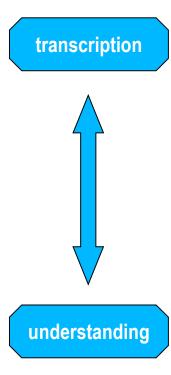
-Automatic Speech Recognition

- Transcription
- « Rich »Transcription

-Information Extraction

-Analysis

- classification
- Syntactic, semantic
- Extracting entities
- Relations between entities
-





Spoken Language Understanding

- Three applicative frameworks
 - Human-Machine spoken dialogue
 - Call-routing
 - Form-filling
 - Negotiation
 - Speech mining / Voice Search
 - Broadcast News
 - Large speech archives (e.g. Malach, INA, etc.)
 - Call centers
 - Speech to Speech Translation





Problem formulation

- Four main issues:
 - How to represent the meaning of a spoken message?
 - Choice of a Meaning Representation Language
 - What kind of models and algorithms can we use to perform understanding?
 - Choice of an interpretation paradigm
 - Which corpus and wich annotations to develop/train/evaluate an SLU system?
 - Choice of an applicative framework
 - Evaluating SLU systems?
 - Global vs. Modular evaluation





Problem formulation

- Processing text vs. Processing speech messages
 - SLU = Natural Language Processing on ASR transcriptions?
 - Integrating ASR and SLU processes
- Dealing with deployed SLU systems
 - Robustness issues
 - Real corpus = real life issues
 - « Expecting the inexpected »





How to represent the meaning of a spoken message?





Choice of a Meaning Representation Language

- Two different point of views
 - General view
 - « meaning » as the composition of basic constituents
 - Definition of constituents and relations independent from a given application
 - Application specific view
 - « interpretation » = « A representation that can be executed by an interpreter in order to change the state of the system » (Speech Communication 48 - SLU)
 - Goal of SLU from a system point of view
 - → SYSTEM INTERPRETATION





Choice of a Meaning Representation Language

- Can be defined by the application framework
 - In a call-routing application
 - Call-type
 - In a database query application
 - SQL query
 - In a directory assistance application
 - The entry in the directory
 - In a speech mining / voice search application
 - Distillation
 - Request: topic, genre, enitites, ...



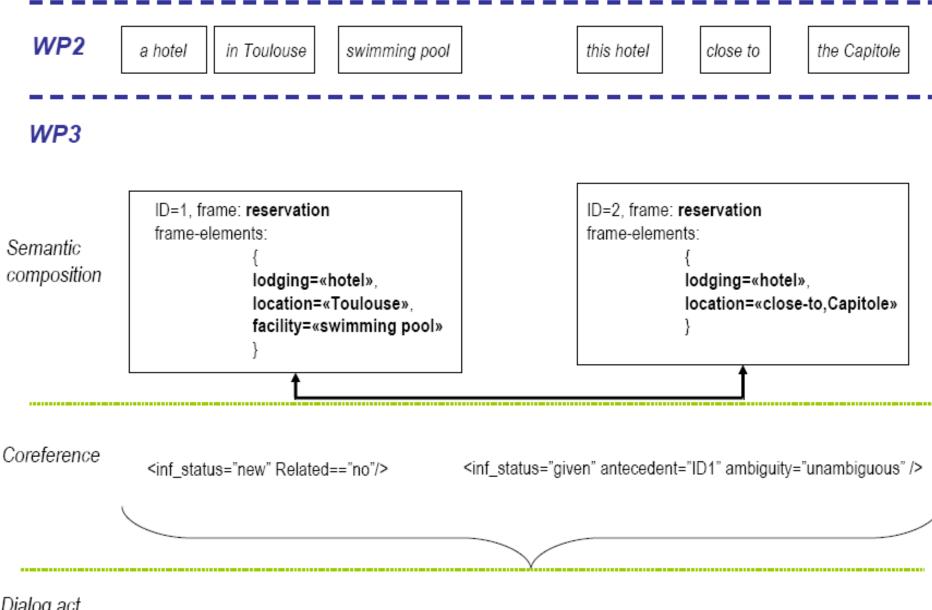


Choice of a Meaning Representation Language

- Can be a formal language
 - Flat representation → « concepts »
 - Named entities, Sequences of keywords, Verbs, ...
 - Structured representation
 - Logical formulae
 - predicate/argument structure
 - PropBank
 - FrameNet
 - + Dialog act
 - + reference resolution
 - Example: LUNA







Dialog act

What kind of models and algorithms can we use to perform understanding?





- Different points of view
 - Understanding is a classification task!
 - Understanding is a translation task!
 - Understanding is a parsing task!





Understanding is a classification task

- Mapping a speech message to a label
 - Call-type, dialog act, ...
- Direct system interpretation of a message
- Classifiers
 - SVM, Boosting, decision tree
- Examples
 - HowMaylHelpYou? (Boosting, SVM)
 - Semantic Classification Trees (on ATIS)
 - Dialog act tagging (CALO meeting)





Understanding is a translation task

- Translation to a formal semantic language
- Related to tagging approaches (e.g. POS tagging)
- Main model: Concept decoding
 - Mapping a sequence of words to a sequence of attribute/ value tokens
- Main approaches
 - Hidden Markov Models
 - MaxEnt tagger
 - Conditional Random Fields





Understanding is a translation task

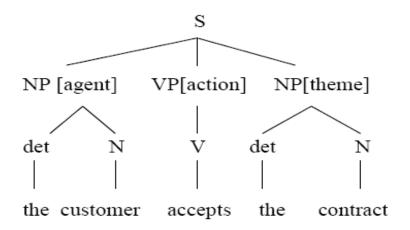
- System interpretation
 - Concept composition
- Examples
 - Chronus (Pieracini & Levin)
 - HMM based model on ATIS
 - Comparison generative/discriminative methods
 - Raymond & Riccardi (Interspeech 2007)
 - Hahn et al. (Interspeech 2008)





Understanding is a parsing task

- syntactic/semantic parsing
 - Concepts = leaves in a parse tree
 - System intepretation
 - obtained directly from the parse tree







Understanding is a parsing task

- Examples
 - Full parse: mapping syntactic trees to semantic trees
 - Deep Understanding (Allen, ACL 2007)
 - Shallow parsing
 - Robust parsing TINA (MIT)
 - Parsing + Semantic rôle labelling
 - SLU with parsing+SVM classifiers (Moschitti, ASRU 2007)





- Generik or application specific?
 - Some generik corpora available
 - Tree Bank, Frame corpora, Named Entity, ...
 - But limited coverage and mostly for English
 - Some generik linguistic ressources available
 - WordNet, FrameNet, PropBank, ...
 - But limited coverage and mostly for English
 - But in both cases
 - Need for application specific corpora/knowledge ressources
 - Need to collect examples in both cases





- Corpus based methods
 - Collecting examples to build a corpus
 - Annotation thanks to an annotation guide
 - No need of handcrafted rules defined by experts but...
 - → need a semantic model anyway
 - To define the annotation model
 - To write the annotation guide
 - Experts needed to train the annotators
 - Incremental process when examples are collected
 - Improving the semantic model and the annotation guide





- Knowledge based methods
 - Hand crafted rules and grammars
 - To detect, extract and compose semantic entities
 - Can be seen as a procedural version of the annotation guide
 - Bootstrap with a few examples
 - Incremental process
 - Rules and grammars are improved as new examples are collected
 - e.g. Example-based learning



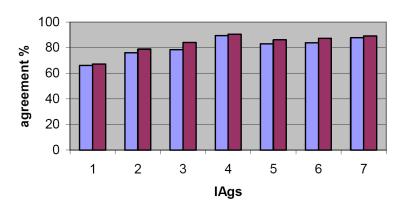


Example on the French MEDIA corpus

Relation between the training corpus size and the concept error rate

Corpus size	25	50	100	200	400	600	720
CER	46.0	43.7	34.6	31.9	26.3	24.2	24.3
correct	61.9%	63.3%	70.9%	74.7%	79.6%	80.8%	81.3%

Inter-annotator agreement according to the amount of dialog annotated







Which corpus and wich annotations to develop/train/evaluate an SLU system?





Corpus for SLU

- « artificial corpus »
 - Collected through evaluation program (Ex: ATIS, MEDIA)
 - Manual annotations
 - Limited size
 - Application domain
 - Spoken dialogue systems, question answering, speech doc. retrieval
- « real life corpus »
 - Spoken archives (e.g. INA, log files from call centers)
 - Collected from real users of a speech-service
 - Ex: AT&T How May I Help You?, France Telecom Voice Services
 - Annotations = automatic/manual/none
 - Unlimited size
 - Application domain
 - Call-centers, Audio messages, Deployed SDS





Corpus for SLU

Main differences

- Artificial corpus
 - controlled conditions
 - cooperative speakers
 - => little "out-of-domain" data
- Real life corpus = real life issues !!
 - Very spontaneous speech
 - Very large variability
 - Speech: accents, language
 - Usage: different classes of users (new and regulars)
 - Unpredictable behaviors
 - Comments, incoherence





French BN corpus with Named Entities annotations: ESTER

```
<ENAMEX TYPE= "PERSON"> Patricia Martin <\ENAMEX>, que voici, que voilà!
oh, bonjour <ENAMEX TYPE= "PERSON"> Nicolas Stoufflet <\ENAMEX>.
<ENAMEX TYPE="ORG"> France-Inter <\ENAMEX> , <TIMEX TYPE=TIME> 7 heures </TIMEX>.
le journal, <ENAMEX TYPE= "PERSON"> Simon Tivolle <\ENAMEX>. bonjour!
<TIMEX TYPE=DATE> lundi 7 décembre <\TIMEX TYPE=DATE>. deux incendies <TIMEX TYPE=TIME> cette nuit
</TIMEX> en région parisienne, dans une maison de retraite de <ENAMEX TYPE=LOCATION> Livry-Gargan
en Seine-Saint-Denis <\ENAMEX>, 7 personnes ont péri dans les flammes.
et puis dans <ENAMEX TYPE=LOCATION> le neuvième arrondissement de Paris <\ENAMEX>,
le feu a pris dans un immeuble d'habitation et 3 personnes ont été tuées.
le sculpteur <ENAMEX TYPE= "PERSON"> César <\ENAMEX> est décédé
<TIMEX TYPE=DATE> hier </TIMEX> à l'âge de <COMPTE TYPE=TEMPS> 77 ans </COMPTE>,
il était devenu célèbre grâce à ses compressions et à ses oeuvres réalisées avec de la ferraille.
<ENAMEX TYPE="ORG"> France-Inter <\ENAMEX> ouvre son antenne à <ENAMEX TYPE="ORG"> la chaîne de
l'espoir <\ENAMEX> pour aider les enfants malades, qui n'ont pas les moyens de se soigner.
<ENAMEX TYPE="ORG"> la chaîne de l'espoir <\ENAMEX>, association de médecins et de bénévoles, a
déjà sauvé 5000 enfants.
le quarante-quatrième congrès de la <ENAMEX TYPE="ORG"> CFDT <\ENAMEX> s'ouvre <TIMEX TYPE=DATE>
aujourd'hui </TIMEX> à <ENAMEX TYPE=LOCATION> Lille <\ENAMEX>, un congrès de la décrispation.
et puis ouverture aussi aujourd'hui des discussions à la <ENAMEX TYPE="ORG"> SNCF <\ENAMEX> entre
les syndicats et la direction.
10 mois après l'assassinat du préfet <ENAMEX TYPE= "PERSON"> Érignac <\ENAMEX> en <ENAMEX
TYPE=LOCATION> Corse <\ENAMEX TYPE=LOCATION> , nous ferons le point sur l'enquête.
```





Spoken survey corpus with opinion annotations: SCOrange (France Telecom)

```
oui c'est monsieur NOMS PRENOMS j'avais appelé

donc le service client ouais

<seg label=accueil,pos> j'ai été très bien accueilli </seg>

<seg label=efficacité,pos> bons renseignements </seg>

sauf que

<seg label=efficacité,neg> ça ne fonctionne toujours pas </seg>

donc je sais pas si j'ai fait une mauvaise manipulation ou y a un problème enfin voilà sinon

<seg label=efficacité,pos label=accueil,pos> l'accueil était et les conseils très judicieux </seg>

même si

<seg label=efficacité,neg>} le résultat n'est pas n'est pas là </seg>

merci au revoir
```





Spoken Dialogue corpus (WOZ): MEDIA

п	W^{c_n}	c_n	mode	spécifieur	valeur
1	je vais réserver	command-tache	+		reservation
2	dans cet hôtel hôtel Richard Lenoir	nom-hotel	+		richard lenoir
3	six	nombre-chambre	+	reservation	6
4	chambres individuelles	chambre-type	+		simple
5	pour le trente et un mai	temps-date	+	reservation	31/05
6	deux jours et deux nuits	sejour-nbNuit	+	reservation	2

n	W^{c_n}	c_n	référence	mode	spécifieur	valeur
1	ils	lienRef	guillermo	+	coRef	pluriel
			champ-mars			
			pullman			
2	proches d'	loc-distanceRelative	_	?	hotel	proche
3	un parc	loc-lieuRelatif		?	general-hotel	parcJardin

Concept + Reference + Semantic Frame annotations





Corpus 3000 France Télécom

« standard request »

- désactiver mon transfert
- transfert d'appel
- payer mon facture
- messagerie vocale

« difficult requests »

- je vous appelle à propos de d' une facture qui n' a pas été réglée et qui a été réglée alors je voudrais avoir quelqu' un pour m' expliquer avec
- oui je voudrais un renseignement qui est très important s'il-vous-plaît
- pourquoi j' ai plus de tonalité
- je voudrais savoir si j' ai reçu la facture que je dois payer ou si je n' ai pas reçu de facture ou si je vous dois de l' que je rentre de l' et je vais y retourner c' est tout ce que je veux savoir mon numéro c' est le je sais plus du tout où j' en suis je suis très fatiguée et je retrouve pas la facture si je dois vous payer ou si je vous ai payée je sais rien du tout alors savoir si vous m' avez envoyé une facture le montant et quand je dois vous la payer

« out of domain » requests

- je comprends pas pourquoi on me dit j' entends la sonnerie et puis quand je vais pour décrocher il y a il y a plus rien je comprends pas ça à plusieurs fois à plusieurs ça fait ça
- allo je voudrais connaître le numéro d' un d' un pressing qui a changé de propriétaire et et de numéro de téléphone évidemment je ne sais pas si je suis bien reliée





Evaluating SLU systems?





Why evaluation?

- Main goal = comparing different approaches
- For example :
 - SLU as a parsing process
 - SLU as a tagging process
 - SLU as a classification process
- Therefore ...
 - The Semantic Model used for evaluation must be as independent as possible from a given approach





SLU vs. ASR evaluation

- Evaluation ?
 - Comparing a reference to a prediction
- Main issue
 - On which «objects» this comparison should be performed?
- Automatic Speech Recognition
 - « standard » objects that can be observed (more or less)
 - phoneme, syllable, character, words, etc.
- Spoken Language Understanding
 - No standard !! Nothing can be directly observed



RELY ON A SEMANTIC MODEL !!





What can we evaluate?

- Choice of an evaluation level
 - Global evaluation on the system performance
 - Positive
 - That's what matter to the users !!
 - Evaluate the whole process, the interconnection between the different levels
 - Negative
 - Difficult to put in place and reproduce for a dialogue application
 - « black box » evaluation
 - Multi-level evaluation
 - Positive
 - Modularity
 - Can be done in batch mode
 - Negative
 - What is the real impact on the global performance of an improvement obtained on a given level
 - Risk of performing « artificial » evaluation (e.g. word disambiguisation)





Evaluation measures

Sequence evaluation

- Let:
 - N = # of reference symbols, N' = # of hypothesized symbols
 - i = # insertion; s = # substitution; d = # deletion
- We have:
 - Correct rate : : $T_{cor} = \frac{(N'-i-s)\times 100}{N}$
 - 3 error rates : $T_{ins} = \frac{i \times 100}{N}$ $T_{sub} = \frac{s \times 100}{N}$ $T_{sup} = \frac{d \times 100}{N}$
 - Token Error Rate TER: $T_{TER} = T_{ins} + T_{sub}T_{sup}$
 - Token accuracy, acc: $T_{acc} = 100 T_{TER}$





Evaluation measures

Global evaluation

$$Pr\'{e}cision = \frac{nombre~de~d\'{e}cisions~correctes \times 100}{nombres~de~d\'{e}cisions~produites}$$

$$Rappel = \frac{nombre\ de\ décisions\ correctes \times 100}{nombre\ de\ choix\ dans\ la\ référence}$$

$$F = \frac{2 * Rappel * Précision}{Rappel + Précision}$$

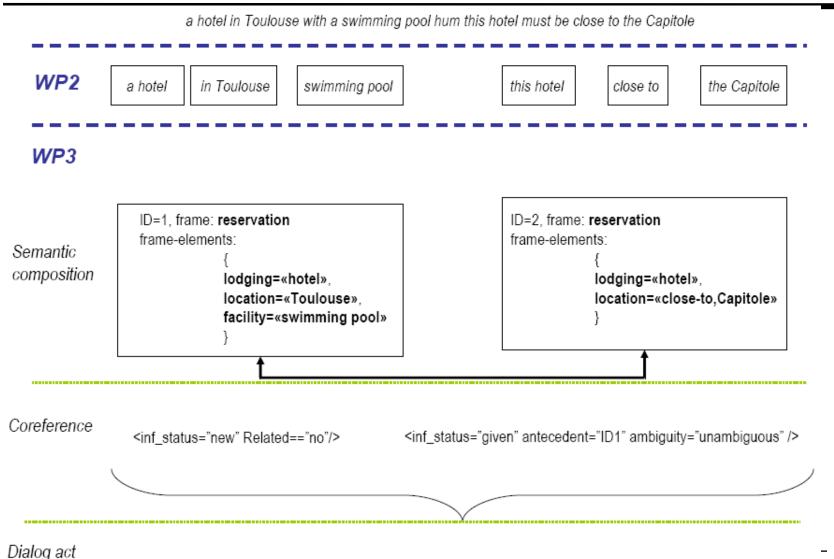
- Oracle rates
 - For a set of hypotheses $L = \{H_1, ..., H_N\}$ and an error rate TE

$$Oracle_{TE}(L) = \min_{1 < i < N} TE(H_i)$$



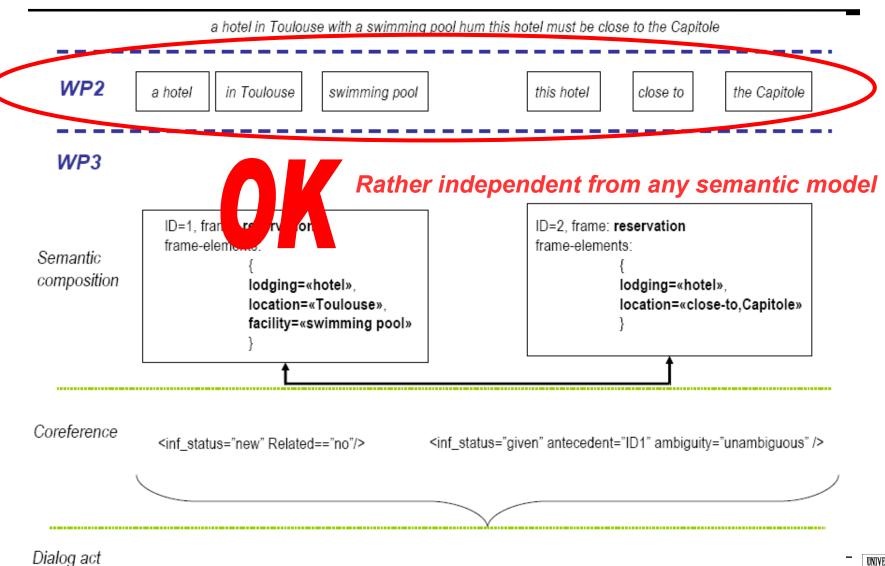


Multi-level evaluation : an example



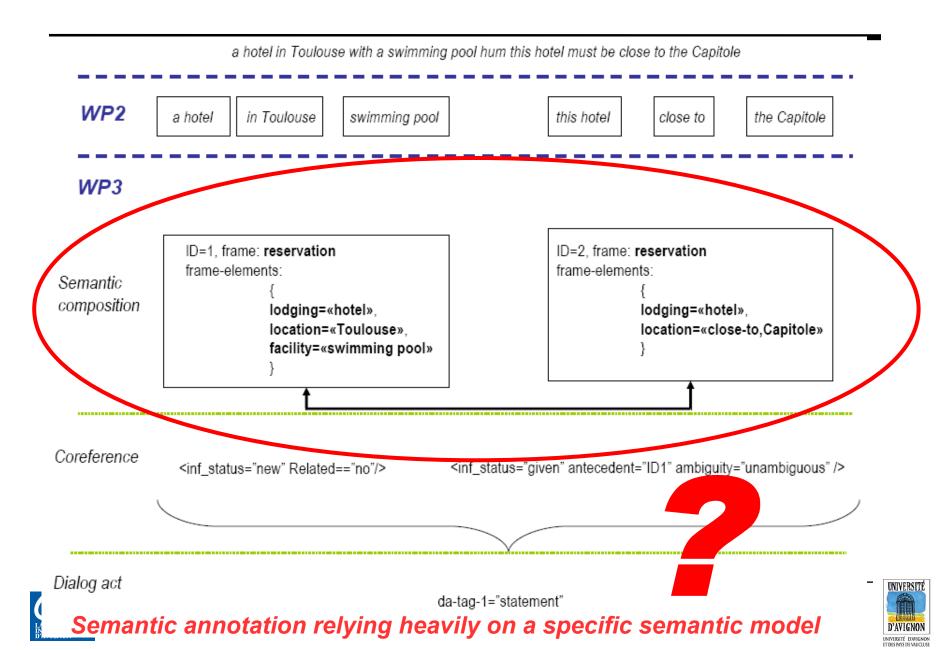


Multi-level evaluation : Genericity of the annotations ?





Multi-level evaluation: Genericity of the annotations?



The Technolangue MEDIA experience

- Evaluation on « traces » of understanding
- Goal
 - Being as independent as possible of a semantic model
 - Going further than the attribute/value level:
 - Mode (+,-,?,~)
 - Semantic specifier (« traces » of hierarchical structures)
 - Co-reference
- Pros
 - Evaluation of 5 very different SLU systems
 - Multi-purpose corpus
- Cons
 - Biased toward tagging/classification approaches
 - Artificial evaluation ?





The Technolangue MEDIA experience

- Example of attribute/value+mode+specifier+reference evaluation
 - Prompt
 - « je vous propose trois hôtels hôtel Guillermo hôtel du champ de mars hôtel Pullman »
 - Message
 - « et j' aimerais savoir s' ils sont proches d' un parc »

п	W^{c_n}	c_n	référence	mode	spécifieur	valeur
1	ils	lienRef	guillermo	+	coRef	pluriel
			champ-mars			
			pullman			
2	proches d'	loc-distanceRelative	_	?	hotel	proche
3	un parc	loc-lieuRelatif		?	general-hotel	parcJardin





Processing text vs. Processing speech messages





SLU vs. Text processing

- SLU = ASR + text processing ?
 - Text documents vs. Speech utterances
 - Automatic transcripts
 - ASR issues
 - Uncertainty, misrecognition, unknown words
 - Partial information
 - All prosodic information missing
 - No structure = stream of words
 - Text
 - "finite" object
 - Text + structure + "graphical" information





SLU vs. Text processing

Main issues

- Text
 - "open world"
 - Capacity of handling new phenomenon
 - Words, compounds, entities
 - Need: Generalization capabilities of the models
- ASR transcript
 - "closed world"
 - ASR lexicon+Language Model define this "world"
 - No unknown words (just misrecognitions !!)
 - → no generalization needed
 - Need: robust detection of the expected information
 - Confidence estimation P(W|A)





Example



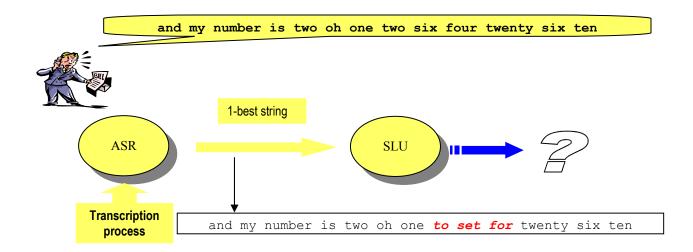




euh bonjour donc c'est XX à l'appareil je sais pas si vous savez très bien qui je suis euh donc par rapport au à la niveau de la satisfaction de ma satisfaction personnelle par rapport à votre service euh je dirai que dans l'ensemble je suis euh plutôt satisfait euh vous avez un très bon service clientèle qui sait écouter qui euh non qui j' ai pas grand chose à dire c' est c'est très très bien sinon ben juste par rapport au à ce que vous avez mis en place euh tout de suite justement c'est une très bonne idée justement d'une façon à ce qu'y ait un taux de réponse euh assez important maintenant c'est vrai qu'on est obligé de rappeler plusieurs fois et encore quand on prend le temps de rappeler pour euh pour euh pour répondre parce que quand on nous dit euh vous allez nous donner vous allez donner euh votre euh vos idées euh vos vos suggestions et ben on n' a rien en tête donc c' est pour ça que j' ai été obligé de raccrocher et de réfléchir à ce que je vais vous dire on ça c'est pas je pense euh que ça c'est le point collectif ou c'est le point négatif et sinon dans l'ensemble je suis très satisfait sinon y a une chose que j' ai annoter euh j' ai deux comptes chez vous euh je trouve ça un peu embêtant de pouvoir euh de pas pouvoir accéder euh aux deux par la même personne quand j' appelle mon service clientèle donc ça je trouve ça un peu dommage que je sois obligé de dépenser en plus parce que faut que je c'est pas le même type euh c'est pas la même personne qui s' occupe de mon dossier donc ce qui aurait été bien c'est quand même regrouper les deux dossiers sous euh euh sous un seul quoi de façon à ce que quand on appelle on puisse accéder aux deux dossiers séparément bien sûr mais les deux dossiers donc voilà euh sinon ben je vous remercie en tous cas pour euh pour votre gentillesse et votre amabilité vos conseillers clientèle sont très très gentils et très à l'écoute et donc je vous en remercie au revoir bonne journée bonne soirée

Integrating ASR and SLU processes

- « sequential approach »
 - ASR => SLU => Manager
 - ASR module produces a text document
 - SLU module processes this text document
 - Manager = exploits SLU output







Integrating ASR and SLU processes

- « integrated approach »
 - ASR ⇔ SLU ⇔ Manager
 - All 3 processes should collaborate
 - Definition of a context (local + global)
 - ASR+SLU+Manager: tuning according to the context
 - ASR output = multiple hypothesis (word lattice)
 - SLU = from a word lattice to an « interpretation lattice »
 - Manager = decision strategy on multiple hypothesis output





Example (global context)



I wanna know why I was charged on September sixth 11 dollars 63 cents for calling 8 5 6 2 1 6 5 5 2 1 Clementon New Jersey for 1 minute

PHONE BILL SEPTEMBER 2001

 DATE
 PHONE#
 DURATION
 PLACE
 AMOUNT

 09062001
 8562165521
 01:00
 Clementon, NJ
 11.63

Exemple: AT&T How May I Help You? tm





Example (local context)

system> in Marseille I propose the Hotel la Fanette

and the Hotel du Port

user> where is the Hotel la Fanette?

ASR> where is the Hotel Lafayette





Integrating ASR and SLU processes

An example of integrated strategy:

The LUNA project







FP6 European project: LUNA

- spoken Language UNderstanding in multilinguAl communication systems
- September 2006

Goal

- Build robust multilingual SLU strategies
- Five main objectives
 - Language Modelling for Speech Understanding;
 - Semantic Modelling for Speech Understanding;
 - Automatic Learning (including Active and On-Line Learning);
 - Robustness issues for SLU;
 - Multilingual portability of SLU components.

Partners

 Loquendo, RWTH Aachen, University of Trento, University of Avignon, France Telecom R&D, CSI-Piemonte, Polish-Japanese Institute of Information Technology, Institute of Computer Science - Polish Academy of Sciences





SLU models in LUNA

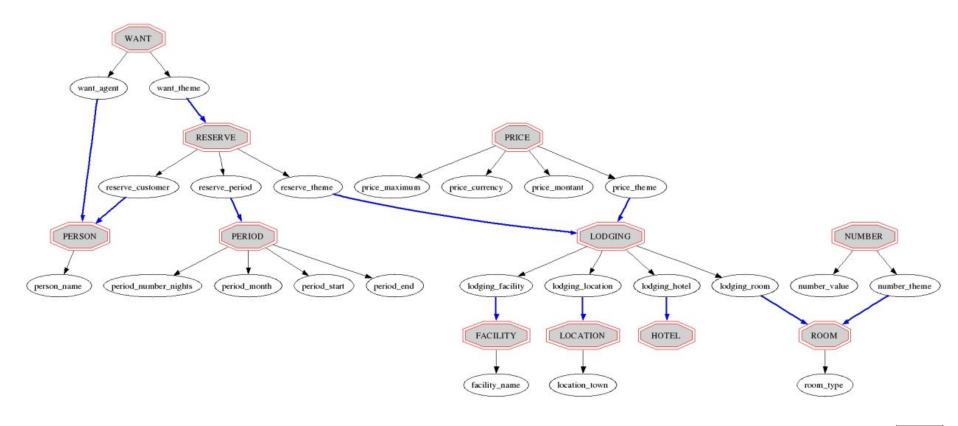
- Multi level semantic representation
 - Concept decoding: from words to concepts
 - Semantic composition: from concepts to interpretations
 - Coreference / Anaphoric relation resolution
 - Speech acts
- Corpus annotation on these levels
 - Concepts
 - word+POS tag+chunk+ Ontology in OWL
 - Interpretations
 - Framenet-like approach
 - Reference resolution
 - ARRAU framework
 - Speech acts
 - Subset of DAMSL
 - DEMO (MEDIA)





Example of LUNA corpus

On the MEDIA corpus



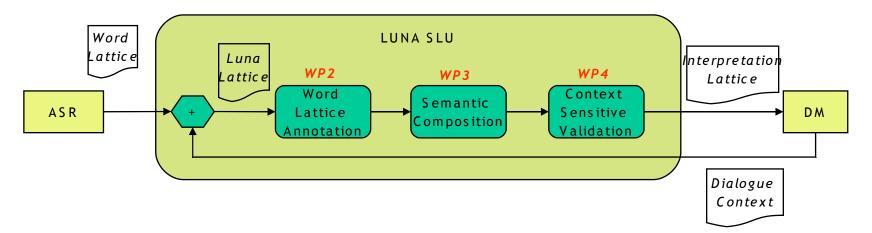




LUNA: an integrated approach

Process

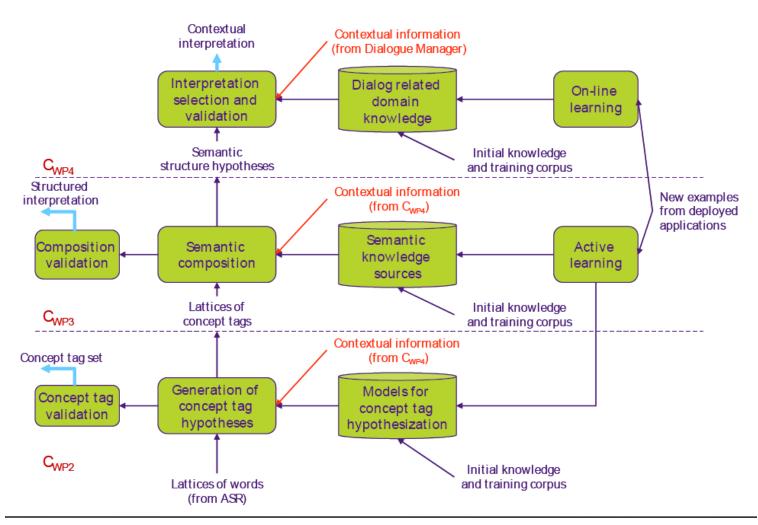
- From a word lattice to an entity lattice
- From an entity lattice to an interpretation lattice
- With references, with speech acts
- Each level using contextual information
 - A priori information on the application context
 - Dynamic information provided bt the dialog manager
- Corpus based + knowledge based methods







LUNA architecture

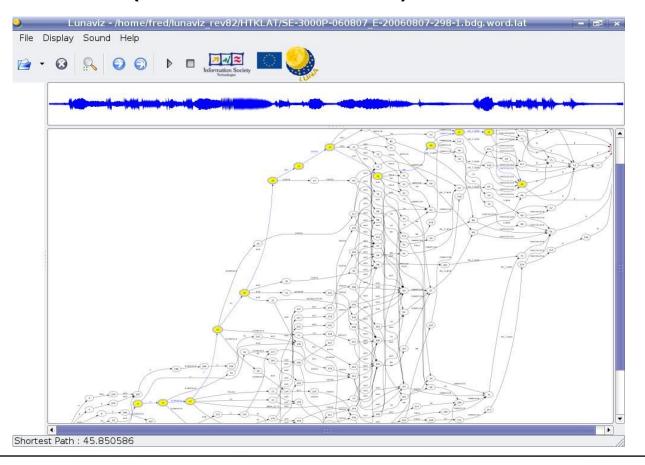






DEMO

FT3000 (Tool: LunaviZ)





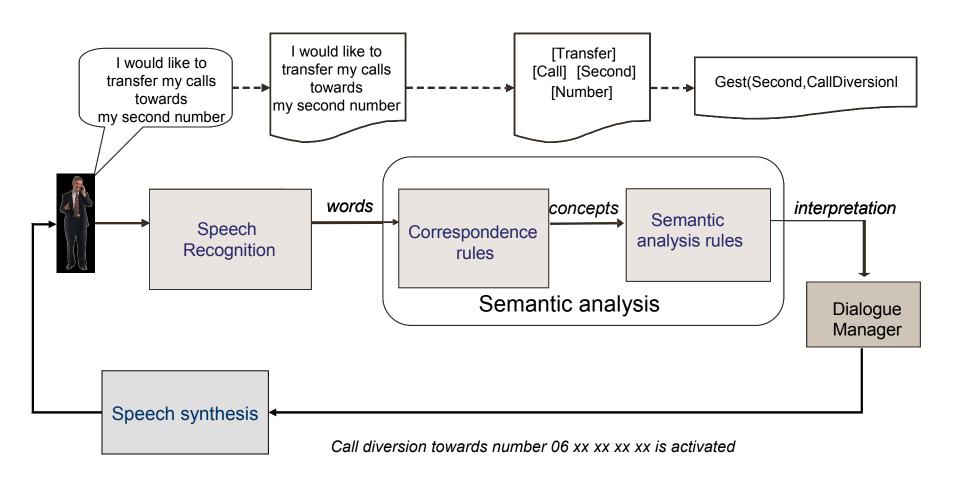


Dealing with deployed SLU systems





An example of deployed application: France Telecom FT3000







FT3000 dialogue corpus

Lexicon: 2,2k words

Training corpus
 42k utterances

Test corpus
 4.5k utterances

- Translation of words into concepts
 - 400 concepts
 - 1200 hand written regular grammars
- Translation of concepts into interpretation
 - 2030 different possible interpretations
 - A set of 3200 hand written inference rules
 - Interpretations expressed by an attribute/value pair





Utterance characterization

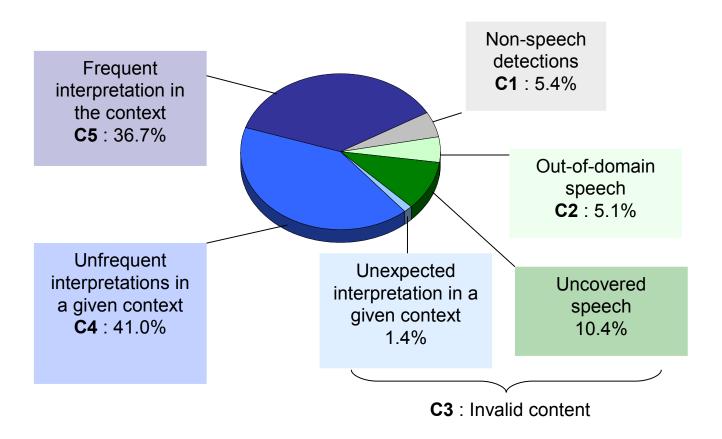
	#	%	example
non-speech C1	246	5.4%	biiiiip
out of domain C2	231	5.1%	bon qu'est-ce que je dois dire là euh well what am I supposed to say now
invalid content C3	536	11.8%	Not covered by interpretation rules on m'appelle tout le temps et y a personne je sais pas qui c'est I receive calls all the time and there's no one I don't know who it is Not expected in a given dialogue phase oui / yes as an answer to an open question
non-frequent C4	1870	41.0%	j'appelle pour avoir un renseignement euh pour euh avoir le service du réveil I'm calling in order to have information about urh for having the wake-up service
frequent C5	1671	36.7%	payer ma facture pay my bill





Utterances variety in real corpora

Real conditions → variety of users / utterances







Different users, different behaviors

• User profiles: experienced vs. new users

	New users	Registred users
# dialogues	350	467
# utterances	1288	717
# words	4141	1454
av. dialogue length	3.7 turns	1.5 turns
av. utterance length	3.2 words	2.0 words
OOV rate	3.6%	1.9%
Disfluency rate	2.8%	2.1%
OOD rate	10.6%	3.3%
Dialogues with OOD	14.3%	3.3%

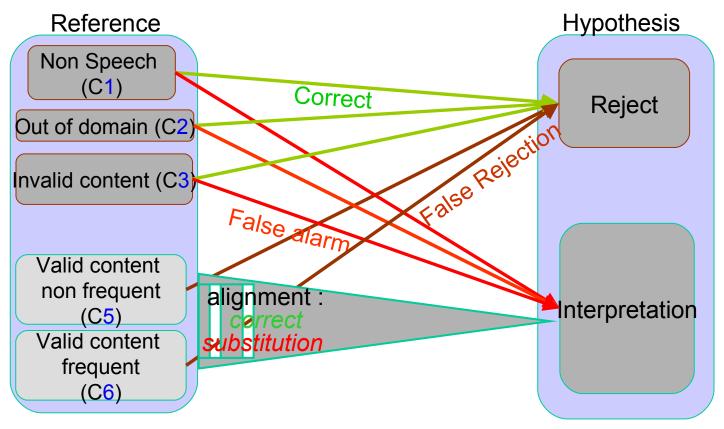
OOV=out of vocabulary word OOD=out of domain utterance

Experienced users prefer keywords and don't make comments!!





Dialogue-oriented characterization and evaluation



$$IER = \frac{nb(False\ Alarms) + nb(False\ Rejections) + nb(Substitutions)}{nb(Valid\ Content)}$$





A few comments as a conclusion ...





Comment & Conclusion

- SLU is not speech dictation!
 - Can't have always a good match between training data and field data
 - Must integrate ASR and SLU processes
- Processing speech transcripts is not processing text!
 - Dealing with uncertainty
 - Specificities of speech transcripts





Comment & Conclusion

- A speech message can only be understood with its context of utterance
 - Local + global context
- A speech message is not just made with words
 - Acoustic and prosodic information are crucial
 - Voice quality
 - Emotion
 - Genre
 - •







Thank you



